

PROJ. 3

SEANCE 1

①

Démontrer que C_1 est non décif. et C_2 si, médiane par entropie

①

C_1 n'est pas préfixé.

'10' est aussi le début du code '1001'

C_1 n'est pas uniquement déchiffable

Ex. 10010

↓
S5 - S1 oppure S2 - S1 - S2

②

C_2 est préfixé

↓

Puisqu'il est préfixé il est donc UNIQUEMENT DÉCHIFFABLE

• Calcul longueur moyenne de chaque code

$$\bar{N} = \sum_{i=1}^N p_i N_i$$

N_i = n. bit parole
 p_i = probabilité

$$N_1 \geq \sum_i p_i N_i = (0.5 \cdot 1) + (0.18 + 0.14) \cdot 2 + (0.12 \cdot 3) + 0.06 \cdot 4 = 1.74$$

$$N_2 \geq \sum_i p_i N_i = (0.5 + 0.18 + 0.14) \cdot 2 + (0.12 + 0.06) \cdot 3 = 2.18$$

• Déterminons $\langle N_{\min} \rangle$, la longueur moyenne minimum de mots de tout codage binaire → ENTROPIE

$$H = - \sum p_i \log_2 p_i$$

$$= - (0.5 \log_2 0.5 + 0.18 \log_2 0.18 + 0.14 \log_2 0.14 + 0.12 \log_2 0.12 + 0.06 \log_2 0.06)$$

$$= 1.953$$

CODE PAS UNIQUEMENT DE CHIFFRABUE

CODE UNIQUEMENT DE CHIFFRABIE (colice ottimo)

CODE ABSOLUTEMENT OPTIMO (conditions ideale)

$$N_1 \subset H$$
$$N_2 > H$$

code dec (on peut l'optimiser)

Chemin code avec 5 caractères

- 2 avec longueur 2
- 2 " " 3
- 1 " " 4

Ex. code N:

$S_1 = 00$


$S_2 = 11$

$S_3 = 101$

$S_4 = 010$

$S_5 = 1000$

→ code bien déchiffable
puisque l'on a choisi
préfixé



→ On a de peur qu'elles ne sont pas méconnaissables pour que le code soit déchiffable, on peut avoir un code plus court →

On a le code N_{cor} .

$$S_1 = 00$$

$$S_2 = 11$$

$$S_3 = 101$$

$$S_4 = 01$$

$$S_5 = 100$$

$$\langle N \rangle = (p_1 + p_2) \cdot 2 + (p_3 + p_4) \cdot 3 + p_5 \cdot 4$$

$$\langle N_{cor} \rangle = (p_1 + p_2 + p_3) \cdot 2 + (p_4 + p_5) \cdot 3$$

→ N_{cor} plus court !

②

$$p_1 = 0.45$$

$$p_2 = 0.23$$

$$p_3 = 0.16$$

$$p_4 = 0.14$$

$$p_5 = 0.05$$

$$\langle N_{cor} \rangle = (p_1 + p_2 + p_3) \cdot 2 + (p_4 + p_5) \cdot 3 = 2.19$$

$$H = - \sum_i p_i \log p_i$$

$$= - (0.45 \log_2 0.45 + 0.23 \log_2 0.23 + 0.16 \log_2 0.16 + \\ + 0.14 \log_2 0.14 + 0.05 \log_2 0.05)$$

$$= 2.019$$


$$\Rightarrow \langle N_{cor} \rangle > H$$

ceci est optimal



mais on peut l'optimiser
pour avoir $N = H$

③ On cherche un code plus optimisé avec la
MÉTHODE DE HUFFMAN



↓

$S_1 : 0$
 $S_2 : 10$
 $S_3 : 110$
 $S_4 : 1111$
 $S_5 : 1110$

$$\rightarrow \langle N_{\text{Huffman}} \rangle = (p_1 \cdot 1) + (p_2 \cdot 2) + (p_4 + p_5) \cdot 4 + p_3 \cdot 3 =$$

$$= 2.09 < \langle N_{\text{ca}} \rangle$$

↓

$\left(\frac{N_{\text{Huff}} \text{ migliore puche più vicino a } H}{N_{\text{Huff}}} \right)$

N_{Huff} MEILLEUR CODE PARCEQUE PLUS PROCHE A H.

③

CODAGE RLE et QUANTIFICATION

① On a la seq. x

↓
En codage RLE est

$(2, 6) (5, 3) (7, 8) (0, 6) (1, 6)$ avec (x, m) pour m répétitions de x

↓
0 bit par lettre (x code sur 1 octet)
5 bit par codificateur de répétition (m)

↓
on code $(x, \textcircled{m}) \rightarrow 13 \text{ bits } (8+5)$

↓
Le champ \textcircled{m} peut coder jusqu'à $2^5 - 1 = 31$ mais
puisque il n'y peut pas avoir 0 répétitions, on peut décaler le
le code et "00000" équivaut à 1 répétition
"00010" équivaut à 3 répétitions

↓
 m jusqu'à 32

Un couple code sur 13 bits peut remplacer 32 entiers
consecutives identiques donc $32 \cdot 8 = 256 \text{ bits}$

↓
TAUX de COMPRESSION $\gamma = \frac{13}{256} = 5\%$

Dans le cas idéal où on veut coder une séquence de m octets, on peut coder le seq avec $\left(\frac{m}{32}\right) \rightarrow \text{ent}_{\text{sup}}\left(\frac{m}{32}\right) \textcircled{*}$

↓

Il suffit donc $\text{ent}_{\text{sup}}\left(\frac{m}{32}\right) \cdot \frac{13}{8} \rightarrow \text{ent}_{\text{sup}}\left(\frac{m}{32}\right) \frac{13}{8}$

Ex. • une suite de 64 '2' normalement il est codé en 64 octets

avec ↓ RLE : $(2 \cdot 13) = 26 \text{ bits} \rightarrow 4 \text{ octets}$

• une suite de 10 chiffres tous différents on va avoir $(10 \cdot 13) = 130 \text{ bits} \rightarrow 16 \text{ octets}$

↓

Inverse en codage naturel on a 10

↓

En général : le CODAGE RLE est performant dans le cas où il y a beaucoup d'octets consécutifs identiques, mais il va donner un codage plus volumineux dans le cas où les octets consécutifs sont tous différents.

$\textcircled{*} \text{ent}_{\text{sup}}(x) = x$ si x est entier, $\text{ent}(x) + 1$ sinon

③

On va quantifier la séquence a de 29 caractères

• $Q=4$ on obtient

0 0001 0101 1111 1121 2021 1000 0000

• $Q=8$ on obtient

0 0000 0000 0000 0040 1010 0000 0000

④

Pour reconstituer la séquence initiale a partir de la quantification on peut multiplier par Q

$Q=4$ 0 0004 0404 4444 4484 8084 4000 0000 $=y_1$

$Q=8$ 0 0000 0000 0000 0080 8080 0000 0000 $=y_2$

On va calculer l'ERREUR QUADRATIQUE MOYENNE pour $Q=4$ et $Q=8$ avec

$$E = \frac{1}{m} \sum (y-x)^2$$

$m = m \text{ caractères}$
 $x = \text{seq. initiale}$
 $y = \text{seq. reconstituée}$

On a :

- pour $Q=4$: $E_4^2 = 4.10 \rightarrow E = 2.02$

- pour $Q=8$: $E_8^2 = 17.34 \rightarrow E = 4.16$

$$\rightarrow E_4^2 = (4)(2)^2 + (9)(3)^2 + 10 / 29 = 4.10$$

$$\rightarrow E_8^2 = (7)(2)^2 + (3)(3)^2 + 7 \times 6 + 6 \times 5^2 + 4 / 29$$

\Rightarrow Plus la quantification est faible plus l'erreur est faible

⑤

On applique le CODE RLE sur la séquence quantifiée reconstituée manuellement:

② Pour $Q=4$

0 0004 0404 4444 4404 0004 4000 0000

Devient $(0,4) (4,1) (0,1) (4,1) (0,1) (4,7) (0,1) (4,1) (0,1)$
 $(0,1) (4,2) (0,7)$

↳ $13 \cdot 13 = 169$ bits (contre 232 (29 consec. x 8 bits) à la base)

③ Pour $Q=8$

0 0000 0000 0000 0080 0080 0000 0000

Devient $(0,15) (0,1) (0,1) (0,1) (0,1) (0,1) (0,9)$

↳ $7 \times 13 = 91$ bits (contre 232 à la base)

⇒ En général

- la QUANTIFICATION va augmenter le nombre de répétition qui permet de diminuer la taille de la séquence en RLE
- Avec la quantification plus grande on réduit plus la taille mais on a un erreur plus grand



Il faut trouver un compromis entre QUALITÉ et QUANTITÉ si on se comprend sans trop de pertes avec ces méthodes.